电商销量预测系统·开发方案文档

版本：V1.1

依据文档：《电商销量预测系统项目任务书 V1.0.0》

文档定位：从任务书到可执行开发的桥接文档。本文档负责把「要做什么」拆解为「按什么顺序做、每步交付什么、怎样判定做完」，供研发、测试、答辩评审共用。

阅读约定

标记	含义
✅	任务书已明确，可直接开发，无需再讨论
⚠️	任务书存在缺口或内部冲突，本文档已给出**建议默认值**并标注待确认
🔒	属于硬约束（验收红线），不可自行降级
📌	已由项目负责人确认的结论（见附录 C 决策记录）
⏱️	已在本机实测的数据（见附录 D 性能基准）

V1.1 修订说明

本版根据项目负责人对附录 A 中 Q2 / Q3 / Q6 的确认结论，以及本机性能实测数据，对以下内容做了修订：

修订项	变化
预测粒度	由「二选一待定」改为**三级降级策略**（仓库×商品 / 商品级 / 不可预测）
训练时机	由「预训练 + 可重训」改为**纯预训练推理**（受 1 分钟等待上限约束）
指标口径	明确为**销量加权 MAPE 为主 + 达标序列占比为辅**，基线

修订项	变化
	为移动平均
耗时指标	由 ⚠ 建议值「≤ 3 分钟」改为 📌 硬约束「**≤ 1 分钟**」
性能假设	用本机实测数据替换原估算（见附录 D）

目 录

第一章 产品定位、目标用户与核心价值主张 5

1.1 一句话定位 5

1.2 目标用户与典型场景 5

1.3 核心价值主张 6

1.4 明确不做什么（本期范围红线） 6

1.5 关键成功指标 6

第二章 核心业务流程 7

2.1 主干路径（Happy Path） 7

2.2 关键分支场景清单 9

2.3 任务状态机（后端核心对象） 10

第三章 功能模块清单与优先级 10

3.1 优先级定义 11

3.2 模块总览 11

3.3 MVP 范围界定（一句话版） 15

第四章 整体系统架构与模块分层 15

4.1 架构总览（B/S 前后端分离，✅ 任务书 3.1） 15

4.2 分层职责边界（明确"谁不能干什么"） 16

4.3 前端模块划分建议 17
4.4 后端模块划分建议 18
第五章 关键数据流与核心数据模型 19
5.1 关键数据流 19
5.2 核心数据模型 20
第六章 外部依赖、接口约定与技术风险 26
6.1 外部依赖清单 26
6.2 接口约定 27
6.3 主要技术风险与应对 29
第七章 分阶段开发排期建议与验收标准 31
7.1 阶段划分原则 31
7.2 阶段排期 31
7.3 各阶段验收标准 32
7.4 里程碑与 Go/No-Go 判定 35
附录 A：关键问题确认清单 36
附录 B：术语表 37
附录 C：已确认决策记录 39
C-1 指标统计口径（对应 Q2） 39
C-2 预测粒度（对应 Q3） 40
C-3 训练时机（对应 Q6） 41
附录 D：本机性能实测基准 42
D-1 硬件与软件环境 42
D-2 数据处理耗时（86 万行，与菜鸟分仓数据同规模） 42
D-3 模型训练耗时（LSTM：hidden=32, layers=1, window=14） 43
D-4 对项目的影响 43
D-5 基准测试脚本 44

第一章 产品定位、目标用户与核心价值主张

1.1 一句话定位

一个面向电商中小商家的**零门槛销量预测 Web 应用**：运营人员上传历史销量 CSV，系统自动完成数据清洗、特征工程与 LSTM 多步预测，直接给出未来若干天的销量曲线、误差指标与可导出的预测表，用来指导补货与分仓。

✅ 依据：任务书 2.1 总体目标「用户通过浏览器上传历史销量数据，系统自动完成特征工程并预测未来若干天的销量，输出预测曲线与误差指标，辅助补货与仓储规划」。

1.2 目标用户与典型场景

用户角色	是否 MVP 服务对象	核心诉求	典型使用场景
电商运营 / 补货专员	✅ 主用户	想知道"下周该备多少货"，不想也不懂写代码	每周固定一次，上传最新销量表 → 拿到未来 7/14/30 天预测 → 按预测调整采购单
仓储 / 分仓规划人员	✅ 主用户	判断各仓库货量分配	大促前，按仓库维度看预测曲线，决定主仓与前置仓铺货比例
中小商家老板	⚠ 次要用户	要一个能看结论的简版视图	只看汇总指标与曲线，不参与数据准备
课程评审 / 答辩老师	✅ 隐性用户	验证技术方案完整性与真实性	现场演示一遍完整链路
数据科学家	❌ 非目标用户	需要深度调参与模型可解释性	本项目不提供，理由是任务书定位为"无需掌握编程技能"

1.3 核心价值主张

1. **免编程**：全流程 Web 化，无需 Python 环境、无需写 SQL。
2. **端到端自动化**：把"清洗 → 插补 → 特征工程 → 建模 → 评估 → 可视化"打包成一次上传后的自动流程，这是相对"Excel + 手工移动平均"的主要代差。
3. **结果可度量**：不输出一个孤零零的预测值，而是同时给出 MAE / RMSE / MAPE 三个指标，并与移动平均基线对比，让用户知道"这个预测值可不可信"。
4. **结论可落地**：预测结果支持导出，能直接并入现有补货流程，而不是停留在网页上看。
5. **案例示范价值**：以菜鸟"需求预测与分仓规划"公开数据集为基准，结果可复现、可对标。

1.4 明确不做什么（本期范围红线）

以下内容**不做**，避免开发过程中范围蔓延导致延期：

- ✕ 实时/流式销量接入（对接 ERP、电商后台 API 等）——只做 CSV 文件上传。
- ✕ 自动补货下单、库存联动、"一键采购"等决策执行类功能。
- ✕ 多租户 SaaS 化、组织架构、权限角色体系（本期只有"注册用户"一种角色）。
- ✕ 移动端原生 App（响应式 Web 即可满足任务书要求）。
- ✕ 模型在线增量训练 / 自动重训调度（属于 V2.0 迭代项）。
- ✕ **用户上传后即时训练模型** —— 📌 受 1 分钟等待上限约束，LSTM 训练在物理上无法在该时限内完成。系统统一使用预训练模型推理，具体见附录 C-3。

1.5 关键成功指标

指标类别	指标	目标值	来源
算法效果 🔒	加权 MAPE	≤ 20%	任务书 2.2-3；口径见 📌 附录 C-1
算法效果 🔒	加权 MAE / RMSE 相对移	降低 ≥ 15%	任务书 2.2-3；基线为移动

指标类别	指标	目标值	来源
	动平均基线		平均 📌
算法效果 📌	达标序列占比（逐序列 MAPE ≤ 20% 的序列数占比）	≥ 60%（参考值，非硬卡点）	本文档建议，需评审确认
产品可用性 🔒	单次预测任务端到端耗时	**≤ 1 分钟**	📌 项目负责人确认
产品可用性	用户从上传到看到曲线所需操作步数	≤ 5 步	⚠ 本文档建议值
数据质量	上传文件校验前置拦截率	100%（字段缺失/格式错误在入库前拦截）	☑ 任务书 2.2-1
数据质量 📌	预测覆盖率如实披露	100%（L1/L2/L3 序列数与占比必须在结果页展示）	配合三级降级策略
兼容性 🔒	主流浏览器最新两个版本可正常使用	Chrome / Firefox / Safari / Edge	任务书 5.1、6.4

第二章 核心业务流程

2.1 主干路径（Happy Path）

以下为主流程，每一步都标注了**责任模块**与**失败时的分支出口**。

```
[1] 访问站点
    ├─ 未登录 ──→ 跳转登录页 ──→ [2]
    └─ 已登录 ──→ 直接进入工作台 ──→ [3]


[2] 用户注册 / 登录
    ├─ 注册：邮箱 + 密码 → 校验唯一性 → 写入 users → 自动登录
    └─ 登录：校验密码哈希 → 签发 Token → 前端本地存储
    X 分支：密码错误 3 次 → 提示冷却；账号不存在 → 引导注册
```

[3] 进入「新建预测任务」
    ├─ 方式 A：上传自己的 CSV 文件
    └─ 方式 B：一键加载内置示例数据（菜鸟数据集抽样）

[4] 数据校验（系统自动，秒级返回）
    校验项：必需字段完整性 / 日期可解析 / 时间连续性 / 销量非负
    📌 仓库列为**必需字段**（任务书数据集必含仓库维度），缺失即拒绝
    ✗ 分支 A：字段缺失 → 返回具体缺失列名与期望格式 → 回到 [3]
    ✗ 分支 B：时间有断档 → 提示断档区间，用户选择「自动插值补齐」或「放弃」
    ✗ 分支 C：存在负值/异常尖峰 → 提示将按截断规则处理 → 用户确认后继续
    ✗ 分支 D 📌：序列数超上限 → 提示需筛选商品后重试（上限见 6.3 R5）

[5] 选择预测参数
    - 预测粒度：仓库 × 商品（📌 主粒度）/ 商品级汇总视图
    - 预测步长：未来 7 / 14 / 30 天（默认 7）
    - 是否纳入节假日特征：是 / 否（默认是）
    📌 不含"是否重新训练"选项 —— 统一使用预训练模型（见附录 C-3）
    → 提交任务

[6] 后端执行预测流水线（📌 目标 ≤ 1 分钟，见附录 D 实测）
    6.1 缺失值线性插值填补
    6.2 异常销量尖峰截断（阈值法）
    6.3 归一化（📌 按序列独立做，不做全局归一化）
    6.4 滑动窗口切分样本
    6.5 特征构造：星期、月份、节假日、滞后销量、滚动均值
    6.6 📌 序列三级分级（L1 仓库×商品 / L2 商品级 / L3 不可预测），见附录 C-2
    6.7 📌 计算移动平均基线（全量覆盖，用于对照与兜底）
    6.8 📌 加载**预训练** LSTM 模型，批量推理（不训练）
    6.9 计算加权 MAE / RMSE / MAPE + 达标序列占比，与基线对比（口径见附录 C-1）
    ✗ 分支：任一环节异常 → 任务置为「失败」+ 记录错误原因 → 前端可重试
    ✗ 分支：总耗时超 1 分钟 → 中止并返回"数据量过大"提示（软失败）

[7] 结果展示
    - 折线图：历史销量实线 + 预测曲线虚线（可选置信提示）
    - 指标卡：加权 MAE / RMSE / MAPE + 相对基线提升百分比
    - 📌 覆盖率披露：L1 / L2 / L3 序列数与占比
    - 分商品预测表格（📌 标注每条的 granularity_level 与置信度）
    ✗ 分支：加权 MAPE > 20% → 页面显著位置提示"本次预测误差偏高，建议谨慎参考"，并给出可能原因（数据量不足 / 波动过大）

[8] 结果处置
    ├─ 导出 CSV / Excel
    └─ 自动存档到「历史记录」

[9] 历史记录

列表查看 → 点入详情看曲线对比 → 支持两个任务曲线叠加对比 → 可再次导出

✗ 分支：删除历史记录 → 二次确认后软删除

2.2 关键分支场景清单

编号	场景	触发条件	系统行为	归属阶段
B1	文件格式不支持	上传非 CSV / 超过大小上限	前端即时拦截并提示	P1
B2	必需字段缺失	缺少商品/仓库/日期/销量任一列	拒绝入库，返回缺列名 + 标准模板下载链接	P1
B3	日期格式混乱	无法统一解析	提示支持的格式（YYYY-MM-DD 优先），拒绝入库	P1
B4	时间序列断档	日期不连续	提示断档区间，提供"自动插值 / 放弃"二选一	P1
B5	数据量不足	有效历史 < 窗口长度 × 2	拒绝执行，提示最少需要的天数	P1
B6	📌 序列数超上限	待预测序列数 > 上限（建议 1000）	提示需筛选商品后重试，不启动流水线	P1
B7	📌 总耗时超限	端到端超过 1 分钟	软失败：返回"数据量过大"提示 + 已完成序列数，不给 502	P1
B8	📌 序列历史稀疏	该组合有效点数 < 90	三级分级：L2 降级到商品级分摊 / L3 标记不可预测	P1
B9	预测误差超标	加权 MAPE > 20%	结果页显著标注，提示原因与免责声明	P1
B10	📌 长尾/新品序列	序列几乎全为零 / 极稀疏	走移动平均规则兜底，标注"低置信度"	P1
B11	并发任务冲突	同一用户同时提交多个任务	队列串行执行，前端显示排队位置	P2
B12	会话过期	Token 失效	返回 401 → 前端跳登录并保留草稿参数	P1

编号	场景	触发条件	系统行为	归属阶段
B13	大促异常冲击	序列出现极端尖峰	在结果页标注"该时段为异常区间，预测参考性下降"	P2
B14	📌 图显存不足	GPU OOM（2GB 显存被其他程序占用）	自动回退到 CPU 推理，功能不中断	P1

2.3 任务状态机（后端核心对象）

📌 因取消"即时训练"，不存在需要长时间排队的任务，状态机已简化（去掉 `queued`）：

```
created（已创建，参数待校验）
   │ 校验通过
   ▼
running（运行中，📌 目标 ≤ 1 分钟）
   ├─ 成功 ──→ succeeded（已成功）──→ 前端可看结果、可导出
   └─ 异常 ──→ failed（已失败）────→ 记录 error_code + error_msg，允许重试
                                          ├─ E_TIMEOUT：超 1 分钟
                                          ├─ E_TOO_MANY_SERIES：序列数超上限
                                          └─ E_INFER_FAIL：推理异常
```

⚠ 需确认：任务失败后是否允许"原参数一键重试"，还是必须重新走一遍参数页？建议**允许一键重试**，降低用户挫败感。

第三章 功能模块清单与优先级

3.1 优先级定义

级别	含义	判定标准
P0	MVP 必备	缺失则主流程跑不通，或直接违背任务书硬性目标
P1	MVP 必备	主流程可跑通，但会显著影响可用性 / 数据正确性
P2	二期迭代	提升体验或扩展场景，MVP 可用人工替代
P3	远期规划	明确不在本期承诺范围

3.2 模块总览

M1 用户管理模块（✅ 任务书 2.2-6）

编号	功能点	优先级	说明
M1-1	邮箱注册	P0	邮箱唯一、密码强度校验、密码哈希存储（不可明文）
M1-2	登录 / 登出	P0	Token 签发与失效
M1-3	个人信息查看与修改	P1	昵称、密码修改
M1-4	找回密码	P2	邮件重置链路，MVP 可用人工协助替代
M1-5	第三方登录	P3	明确不在本期范围

M2 数据上传模块（✅ 任务书 2.2-1）

编号	功能点	优先级	说明
M2-1	CSV 文件上传	P0	拖拽 + 点击上传，限制扩展名与大小

编号	功能点	优先级	说明
M2-2	示例数据一键加载	P0	内置菜鸟数据集抽样文件，供无数据用户体验
M2-3	字段完整性校验	P0	必需列：商品、仓库、日期、销量
M2-4	时间连续性校验	P0	检测断档并返回具体区间
M2-5	数据预览（前 N 行）	P1	让用户确认"系统读到的和我以为的一致"
M2-6	错误明细下载	P1	把不合格行导出，便于用户在原表改完重传
M2-7	多文件批量上传	P2	MVP 单文件即可
M2-8	标准模板下载	P1	降低用户第一次使用时的试错成本

M3 特征工程与预处理模块（☑ 任务书 2.2-2）

编号	功能点	优先级	说明
M3-1	缺失值线性插值填补	P0	任务书明确指定方法
M3-2	异常尖峰截断处理	P0	阈值法，阈值需可配置
M3-3	归一化	P0	📌 **按序列独立归一化**，训练集统计量归一，推理复用同一统计量（防止泄漏与量级干扰）
M3-4	滑动窗口样本切分	P0	窗口长度可变，作为超参数
M3-5	基础时间特征	P0	星期、月份、节假日
M3-6	滞后特征	P0	滞后销量（lag）
M3-7	滚动统计特征	P0	滚动均值（可扩展滚动标准差）
M3-8	📌 序列分级器（L1/L2/L3）	P0	按有效点数判定建模层级，见附录 C-2
M3-9	特征重要性 / 相关性输出	P2	帮助用户理解模型，非必须

M4 模型预测模块（✅ 任务书 2.2-3）

📌 本模块已按"纯预训练推理"重构：训练仅发生在**离线阶段**，在线只做推理。

编号	功能点	优先级	说明
M4-1	时序切分（8:1:1）	P0	**必须按时间先后切分**，禁止随机切分（离线训练时使用）
M4-2	多层 LSTM 模型	P0	损失 MSE，Adam + 学习率衰减，早停
M4-3	多步预测输出	P0	一次输出未来 N 天序列
M4-4	📌 指标计算（加权 MAE / RMSE / MAPE + 达标序列占比）	P0	口径见附录 C-1
M4-5	移动平均基线对比	P0	用于证明"降低 15%"这一硬指标；同时作为长尾兜底模型
M4-6	📌 超参数网格搜索（离线）	P1	窗口长度 / 隐藏单元 / 层数 / dropout / 学习率；📌 实测单次训练仅数秒，可承受小规模网格（3×3）
M4-7	模型文件持久化与版本管理	P0	保存最优权重，记录超参数与训练时间
M4-8	📌 预训练模型推理（唯一在线路径）	P0	由 P1 提升为 P0：这是在线预测的唯一方式
M4-9	📌 设备自动选择与回退（CUDA→CPU）	P0	2GB 显存 OOM 时自动回退，保证不中断（见附录 D）
M4-10	📌 批量推理	P0	打包成 batch 一次前向，禁止逐序列循环调用
M4-11	自动重训调度	P3	明确不在本期范围（见 1.4）
M4-12	预测置信区间	P2	让用户感知不确定性

M5 结果可视化模块（✅ 任务书 2.2-4）

编号	功能点	优先级	说明
M5-1	历史 vs 预测折线对比图	P0	核心视觉产出
M5-2	📌 误差指标卡片（加权口径）	P0	加权 MAE / RMSE / MAPE + 基线提升幅度
M5-3	分商品预测表格	P0	支持排序与分页；📌 标注 granularity_level 与置信度
M5-4	预测结果导出	P0	CSV / Excel
M5-5	误差超标警告展示	P0	加权 MAPE > 20% 时的显著提示
M5-6	📌 覆盖率披露面板	P0	展示 L1 / L2 / L3 序列数与占比，如实说明哪些不可预测
M5-7	📌 逐序列 MAPE 分布图	P1	让评审看到误差分布形态，而非单一平均值
M5-8	多 SKU 曲线叠加 / 筛选	P1	商品数量多时的可用性保障
M5-9	图表截图导出	P2	便于写周报

M6 历史记录模块（✅ 任务书 2.2-5）

编号	功能点	优先级	说明
M6-1	预测历史列表	P0	含任务名、时间、粒度、指标摘要
M6-2	历史详情查看	P0	回看当时的曲线与指标
M6-3	历史记录导出	P0	任务书明确要求
M6-4	跨任务曲线对比	P1	任务书"预测曲线对比"的具体落地
M6-5	历史记录删除	P1	软删除 + 二次确认
M6-6	按时间 / 商品检索过滤	P2	记录变多后的效率手段

M7 系统与运维模块（⚠ 任务书未单列，建议纳入 MVP）

编号	功能点	优先级	说明
M7-1	统一错误响应结构	P0	前后端联调效率的关键
M7-2	操作日志 / 任务日志	P0	排障与答辩演示素材
M7-3	健康检查接口 `/health`	P0	部署验证入口
M7-4	免责声明页脚 / 首启提示	P0	任务书 6.1 要求，属合规红线
M7-5	HTTPS 与数据脱敏	P0	任务书 6.2 要求
M7-6	数据清理策略（历史文件定期清理）	P1	控制磁盘占用
M7-7	监控告警	P2	单机部署场景下可暂缓

3.3 MVP 范围界定（一句话版）

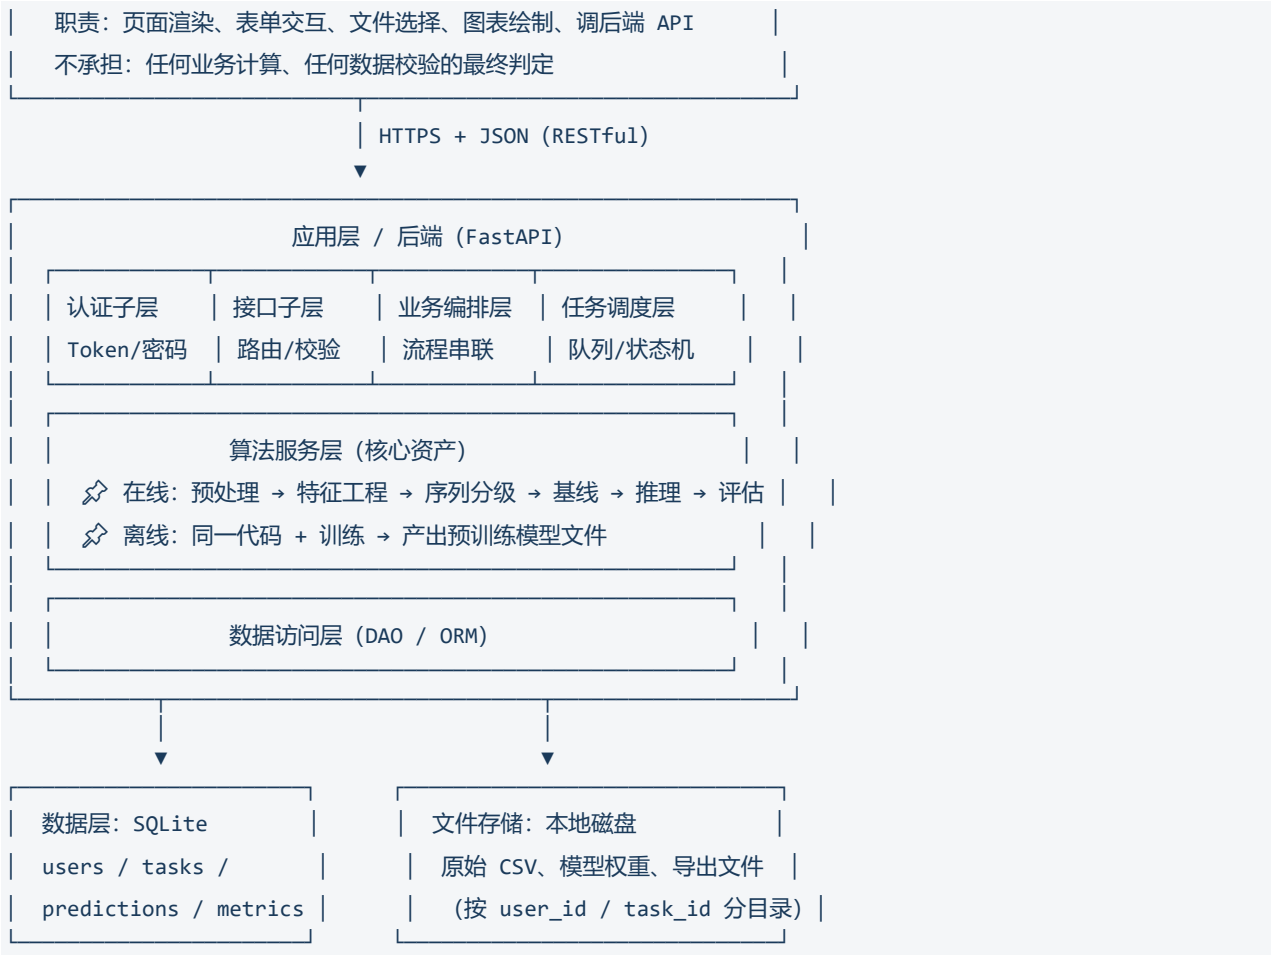
MVP = M1 + M2 + M3 + M4（M4-6/4-8 可降级）+ M5 + M6-1~6-3 + M7-1~7-5

即：注册登录 → 上传/示例数据 → 校验 → 选参数 → 自动跑完整算法链路 → 看曲线与指标 → 导出 → 存历史，这条链路必须 100% 走通。P2 项在 MVP 验收通过后再排期。

第四章 整体系统架构与模块分层

4.1 架构总览（B/S 前后端分离，☑ 任务书 3.1）

```
┌──────────────────────────────────────────────────────────┐
│                    表示层 / 前端（Web 客户端）                │
│   React + TailwindCSS / Ant Design                       │
```



4.2 分层职责边界（明确"谁不能干什么"）

层	负责	明确不负责	边界依据
前端	展示、交互、请求编排、图表渲染	不做指标计算、不做数据清洗、不保存明文密码	避免前后端算法不一致导致结果对不上
接口子层	路由、参数 schema 校验、鉴权、序列化	不写业务规则（如"MAPE 超标要警告"）	校验格式，不校验业务
业务编排层	流程串联、状态流转、异常归类、权限判定	不做矩阵运算	保持编排逻辑可读可测
算法服务层	清洗、特征、序列分级、基线、推理、指标计算	📌 **在线不做训练**；不碰 HTTP、不碰数据库	**可脱离 Web 单独跑通**，这是可测性的前提
数据访问层	CRUD、事务、连接管理	不做业务判断	防 SQL 渗透到上层
数据层	持久化	——	SQLite 单文件，⚠ 见 6.3 风险 R4

架构红线 1：算法服务层必须提供纯函数式入口（输入 DataFrame、输出预测结果与指标），使其能用一个脚本零 Web 依赖地跑完评估，这是保证"加权 MAPE ≤ 20%"这一硬指标可独立复现的关键。

📌 **架构红线 2**：**在线链路与离线训练必须共用同一份算法代码**（`algo/` 目录）。离线训练脚本从 `algo/` 导入，在线服务也从 `algo/` 导入，唯一差别是"模型从哪来"。这样可避免"训练时的预处理"与"推理时的预处理"不一致——这是时序项目最常见的隐藏 bug。

4.3 前端模块划分建议

模块	主要页面 / 组件	说明
认证模块	登录页、注册页	表单校验、错误提示
工作台	任务入口、最近任务卡片	登录后首屏
数据上传	上传区、预览表、校验结果面板	校验失败要能明确指出问题行/列；📌 表头必须含仓库列，缺失直接拒绝并提示
参数配置	粒度选择（固定"仓库×商品"，只读展示）、预测步长、特征开关	默认值要合理，允许"直接提交"；✕ **不提供"在线重新训练"开关**（见 1.4）
结果视图	折线图、指标卡（加权 + 逐序列）、预测表、导出按钮、覆盖度披露面板	核心交付页
覆盖度披露	三级覆盖汇总、逐序列 MAPE 分布直方图	📌 全局指标与局部质量必须同时可见，避免"用少量好序列拉高均值"
历史记录	列表页、详情页、对比视图	支持从历史重新导出
通用	布局、导航、错误边界、免责声明组件	免责声明需全局可达

推荐图表库：ECharts 或 Recharts。⚠ 需确认：任务书未指定，建议按团队熟悉度二选一，**优先 ECharts**（中文文档完善、导图能力强）。

4.4 后端模块划分建议

```
app/
├── api/            # 路由层：auth / upload / predict / history
├── core/           # 配置、安全（哈希、Token）、异常定义
├── models/         # ORM 实体
├── schemas/        # Pydantic 请求/响应模型
├── services/       # 业务编排：task_service、predict_service
├── algo/           # 🔧 算法层（无 Web 依赖，在线离线共用同一份代码）
│   ├── preprocess.py     # 插值、异常截断
│   ├── features.py       # 滑动窗口、时间/滞后/滚动特征
│   ├── classify.py       # 📌 序列分级 L1/L2/L3（按有效历史长度 + 稀疏度）
│   ├── model.py          # LSTM 定义（含设备自动回退）
│   ├── train.py          # 📌 仅离线调用：训练 + 早停 + 网格搜索；服务进程不导入
│   ├── infer.py          # 📌 在线主路径：加载已注册权重 + 批量推理
│   ├── fallback.py       # 📌 L2/L3 规则兜底（同期均值 / 全局均值）
│   └── metrics.py        # 📌 加权 MAE/RMSE/MAPE + 基线 + 达标序列占比
├── dao/            # 数据访问
└── main.py

scripts/            # 📌 离线侧（不参与服务启动）
├── train_and_register.py  # 训练 → 评估 → 写 model_registry → 落盘权重
└── eval_report.py         # 零 Web 依赖跑通"加权 MAPE ≤ 20%"验收脚本
```

关键约束	说明
`algo/` 不得 import `fastapi` / `sqlalchemy`	保证可被离线脚本直接复用（架构红线 1）
`train.py` 不被 `services/` 引用	服务进程内存里不应存在训练相关依赖与图构建逻辑
`classify.py` 的输出是**后续所有环节的输入**	分级结果决定走推理还是走兜底，也决定指标的统计口径
`metrics.py` 只认"预测值 + 真值 + 分级标签"	不关心数据从哪来，因此在线与离线评估可用同一实现

⚠ 需确认：任务书任务分解表第 6 项同时写了"Flask/FastAPI"，而第 3.2 技术选型表确定是 FastAPI。**以 FastAPI 为准**，Flask 属历史残留表述，建议在项目文档中明确统一，避免开发时产生分歧。

第五章 关键数据流与核心数据模型

5.1 关键数据流

数据流 1：上传与校验流

```
用户选择 CSV
  → 前端：扩展名/大小预检（即时失败，不占带宽）
  → POST /api/v1/datasets (multipart)
  → 接口层：schema 校验
  → 业务层：调用 algo.preprocess.validate()
        校验列名 → 校验日期可解析 → 校验时间连续性 → 校验数值合法性
  → 通过：落盘 raw 文件 + 写 datasets 记录 + 返回 dataset_id 与预览数据
  → 失败：返回结构化错误（错误类型 + 定位 + 修复建议），不落盘
```

数据流 2：预测任务流（核心链路，📌 在线同步 ≤ 1 分钟）

```
POST /api/v1/predictions  { dataset_id, granularity, horizon, features }
  → 接口层：schema 校验 + 序列数预检（估算序列数 > 上限则直接拒绝 E_TOO_MANY_SERIES）
  → 创建 task（status=running）→ 同步执行（总预算 60s，📌 不做排队）
  → algo 流水线（各步骤均带耗时埋点，落 task.duration_ms）：
      read raw CSV（已验证过，跳过重复校验）
        → 插值填补 → 异常截断
        → 【序列分级 classify.py】按有效历史长度 + 稀疏度打 L1/L2/L3 标签
        → 按分级分流：
            L1（历史充足）→ 逐序列归一化 → 滑动窗口 + 特征 → 批量推理
            L2（历史偏短）→ 规则兜底（同期均值 / 简单外推）
            L3（无有效历史）→ 全局均值兜底
        → 计算移动平均基线（同一测试段、同一序列集合）
        → 加权指标 + 逐序列 MAPE + 达标序列占比 + L1/L2/L3 覆盖计数
  → 结果写入 predictions（逐条预测值 + granularity_level）+ metrics（任务级）
  → task.status = succeeded，返回 task_id 与完整结果
  → 前端直接渲染（无轮询）
  → 超预算：task.status = failed，error_code = E_TIMEOUT，返回已完成阶段与建议（见 2.2 B7）
```

📌 **与 V1.0 的关键差异**：V1.0 写的是"创建 task → 排队 → 调度器 → 训练 LSTM → 轮询"。

经实测与决策（附录 C-3 + 附录 D），**1 分钟 SLA 物理上排除了在线训练**，因此改为

"同步执行 + 预训练权重推理"。轮询逻辑保留在接口层（用于将来任务变重时平滑演进），

但当前实现路径不触发排队态。

📌 **为什么必须"同一序列集合"算基线**：如果基线在全量序列上算、模型只在 L1 上算，

提升幅度会被系统性放大，属于典型的偷换统计口径。基线必须与模型**同范围、同测试段**。

数据流 3：结果导出流

```
GET /api/v1/predictions/{task_id}/export?format=csv
  → 业务层校验 task 归属（只能导出自己的）
  → 组装 DataFrame（商品，仓库，日期，预测销量，实际值(如有)，误差）
  → 生成导出文件到磁盘 → 返回下载流
  → 同时写 exports 记录（用于数据清理策略）
```

数据流 4：历史回溯流

```
GET /api/v1/history?page=&size=
  → 按 user_id 过滤 → 按创建时间倒序 → 返回任务摘要列表
GET /api/v1/history/{task_id}
  → 校验归属 → 返回该任务完整结果（曲线点 + 指标）
```

5.2 核心数据模型

以下为逻辑模型，⚠ 具体字段长度、索引与约束需在数据库设计文档中细化。所有表均建议含 `created_at`、`updated_at`。

users（用户表）

字段	类型	约束	说明
id	INTEGER	PK, 自增	主键
email	TEXT	UNIQUE, NOT NULL	登录名
password_hash	TEXT	NOT NULL	**只存哈希，禁止明文**
nickname	TEXT	NULL	展示名
status	INTEGER	DEFAULT 1	1 正常 / 0 停用
last_login_at	TEXT	NULL	最近登录时间

datasets（数据集表）

字段	类型	约束	说明
id	INTEGER	PK	主键
user_id	INTEGER	FK→users.id, NOT NULL	归属，**所有查询必须带此条件**
file_name	TEXT	NOT NULL	原始文件名
file_path	TEXT	NOT NULL	磁盘相对路径
row_count	INTEGER	NULL	有效行数
sku_count	INTEGER	NULL	商品数
warehouse_count	INTEGER	NULL	📌 仓库数（仓库列为必需字段）
valid_series_count	INTEGER	NULL	📌 有效序列数（≥ 最小点数的组合数）
date_start / date_end	TEXT	NULL	数据时间范围
is_sample	INTEGER	DEFAULT 0	是否内置示例数据
status	INTEGER	DEFAULT 1	1 可用 / -1 已失效

tasks（预测任务表）

字段	类型	约束	说明
id	INTEGER	PK	主键

字段	类型	约束	说明
user_id	INTEGER	FK→users.id, NOT NULL	归属
dataset_id	INTEGER	FK→datasets.id	输入数据
task_name	TEXT	NULL	用户可命名
granularity	TEXT	NOT NULL	📌 固定为 `warehouse_sku`（主粒度），商品级为汇总视图
horizon	INTEGER	NOT NULL	预测步长（7/14/30）
use_holiday_feature	INTEGER	DEFAULT 1	是否启用节假日特征
status	TEXT	NOT NULL	📌 created/running/succeeded/failed（已去掉 queued）
error_code	TEXT	NULL	失败原因码（E_TIMEOUT / E_TOO_MANY_SERIES / E_INFER_FAIL）
error_msg	TEXT	NULL	失败详情
model_version	TEXT	**NOT NULL**	📌 必填 —— 因为不再有"本次训练的模型"
l1_count / l2_count / l3_count	INTEGER	NULL	📌 三级序列数，用于覆盖率披露
duration_ms	INTEGER	NULL	📌 端到端耗时（用于验证 ≤ 1 分钟的硬指标）
started_at / finished_at	TEXT	NULL	耗时统计
is_deleted	INTEGER	DEFAULT 0	软删除

predictions（预测结果表）

字段	类型	约束	说明
id	INTEGER	PK	主键
task_id	INTEGER	FK→tasks.id, NOT NULL	所属任务
sku_id	TEXT	NOT NULL	商品标识
warehouse_id	TEXT	**NOT NULL**	📌 仓库列为必需字段，不再可空
forecast_date	TEXT	NOT NULL	预测目标日期

字段	类型	约束	说明
predicted_value	REAL	NOT NULL	预测销量
actual_value	REAL	NULL	测试集回填真值（用于对比图）
granularity_level	TEXT	NOT NULL	📌 L1 / L2 / L3，标识建模层级与置信度来源
lower_bound / upper_bound	REAL	NULL	置信区间（P2 启用）

建议索引：📌 `(task_id, warehouse_id, sku_id, forecast_date)` 联合唯一索引。

metrics（任务指标表）

📌 字段已按"加权口径 + 达标序列占比"双口径重构（见附录 C-1）。

字段	类型	约束	说明				
id	INTEGER	PK	主键				
task_id	INTEGER	FK→tasks.id, UNIQUE	与任务一对一				
mae	REAL	NULL	📌 加权 MAE（按销量加权）				
rmse	REAL	NULL	📌 加权 RMSE				
mape	REAL	NULL	📌 加权 MAPE（即 WAPE = Σ\	y-ŷ\	/ Σ\	y\	)
baseline_mae	REAL	NULL	📌 移动平均基线加权 MAE（同口径、同预测点）				

字段	类型	约束	说明				
baseline_rmse	REAL	NULL	📌 移动平均基线加权 RMSE				
baseline_mape	REAL	NULL	📌 移动平均基线加权 MAPE				
improvement_pct	REAL	NULL	加权 MAE 相对基线提升百分比 🔒 ≥15%				
series_total	INTEGER	NULL	📌 参与评估的序列总数（分母）				
series_passed	INTEGER	NULL	📌 逐序列 MAPE ≤ 20% 的序列数				
series_pass_rate	REAL	NULL	📌 达标序列占比 = passed / total				
l1_mape / l2_mape	REAL	NULL	📌 L1 与 L2 的 MAPE **分开统计**，不得混算后宣称达标				
is_over_threshold	INTEGER	NULL	📌 加权 MAPE 是否超 20%，驱动前端警告				
eval_note	TEXT	NULL	📌 评估前提说明（如 "预训练模型未针对输入数据微调"）				

model_registry（模型版本表）📌 由"建议新增"升为必需

字段	类型	说明
id	INTEGER	主键
version	TEXT	版本号（如 `lstm_v1`）
file_path	TEXT	权重文件路径
window_size / hidden_size / num_layers / dropout / lr	——	关键超参数留存
train_data_range	TEXT	训练数据时间范围
val_mae / val_rmse / val_mape	REAL	验证集指标（加权口径）
peak_memory_mb	REAL	📌 训练峰值显存，便于判断是否可在线复现
device	TEXT	📌 训练设备（cuda / cpu），用于追溯
trained_at	TEXT	训练时间

📌 因为在线预测**完全依赖**这张表取模型，它从"建议新增"变为 P0 必需的交付物组成部分。

operation_logs（操作日志表，建议新增）

字段	类型	说明
id	INTEGER	主键
user_id	INTEGER	操作人
action	TEXT	login / upload / predict / export
target_id	TEXT	关联对象 id
result	TEXT	success / fail
detail	TEXT	详情（错误栈摘要等）
created_at	TEXT	时间

⚠ **待确认的数据模型问题**

1. **是否需要"仓库"独立成表？** 📌 已查证菜鸟数据集为 963 商品 × 5 分仓，仓库维度以分组键形式使用即可，**MVP 不建独立表**；若后续要做仓库别名、区域、优先级管理，V2.0 再拆。
2. **商品编码是否可能跨数据集冲突？** 若用户 A 与用户 B 用同一 `sku_id`，必须靠 `user_id + dataset_id` 隔离。**所有查询必须带用户维度**，这是数据隔离的红线。
3. **原始 CSV 是否保留？** 保留利于复现与重跑，但占磁盘。建议保留，并配合 6.3 的清理策略。📌 提醒：本机 C 盘空闲空间有限（实测约 29GB），中间文件应放在工作区内并定期清理。

第六章 外部依赖、接口约定与技术风险

6.1 外部依赖清单

依赖项	用途	获取方式	风险等级	应对
菜鸟"需求预测与分仓规划"数据集	训练与演示基准数据	阿里天池，URL 见任务书 3.3，**需登录后免费下载**	中	提前下载并本地留存；同时准备抽样版作为内置示例数据
Python 3.12+	运行环境	官方渠道	低	✅ 任务书明确
PyTorch	建模	pip	中	⚠ 版本需锁定，避免与 CUDA/CPU 版本不匹配
pandas / numpy	数据处理	pip	低	注意 pandas 大版本 API 差异
FastAPI + Uvicorn	后端服务	pip	低	✅ 任务书明确
React	前端框架	npm	低	✅ 任务书明确
TailwindCSS / Ant Design	UI	npm	低	⚠ 二者定位有重叠，建议明确分工：

依赖项	用途	获取方式	风险等级	应对
				Ant Design 出组件，Tailwind 做微调
SQLite	数据库	内置	中	⚠ 见 R4
ECharts / Recharts	图表	npm	低	任务书未指定，需选型

6.2 接口约定

6.2.1 通用约定

- **Base Path**：`/api/v1`
- **认证**：`Authorization: Bearer <token>`，除注册/登录/健康检查外全部需要
- **时间格式**：`YYYY-MM-DD`（日期）、`YYYY-MM-DD HH:mm:ss`（时间戳）
- **字符编码**：UTF-8
- **统一响应包**：

```
{
  "code": 0,
  "message": "ok",
  "data": { }
}
```

失败时：

```
{
  "code": 40001,
  "message": "缺少必需字段：销量",
  "data": { "missing_columns": ["销量"], "suggestion": "请按模板补齐后重新上传" }
}
```

6.2.2 错误码规划

区间	含义	示例
0	成功	——
400xx	请求/校验错误	40001 字段缺失、40002 日期无法解析、40003 数据量不足
401xx	认证错误	40101 未登录、40102 Token 失效、40103 密码错误
403xx	权限错误	40301 无权访问他人资源
404xx	资源不存在	40401 任务不存在
500xx	服务内部错误	50001 模型推理失败、50002 文件读写异常

6.2.3 核心接口清单

方法	路径	说明	优先级
POST	`/auth/register`	注册	P0
POST	`/auth/login`	登录，返回 Token	P0
POST	`/auth/logout`	登出	P1
GET	`/users/me`	当前用户信息	P1
PATCH	`/users/me`	修改个人信息 / 密码	P1
POST	`/datasets`	上传 CSV	P0
GET	`/datasets/sample`	加载内置示例数据	P0
GET	`/datasets/{id}/preview`	数据预览	P1
GET	`/datasets/template`	下载标准模板	P1
POST	`/predictions`	创建预测任务	P0
GET	`/predictions/{task_id}/status`	查询任务状态	P0
GET	`/predictions/{task_id}`	获取预测结果	P0
GET	`/predictions/{task_id}/export`	导出结果	P0
GET	`/history`	历史列表	P0
GET	`/history/{task_id}`	历史详情	P0
DELETE	`/history/{task_id}`	删除历史	P1

方法	路径	说明	优先级
GET	`/health`	健康检查	P0

⚠ **需确认的接口约定问题**

1. **任务状态获取方式**：📌 因取消异步长任务（1 分钟内完成），建议 MVP 用**轮询（2 秒间隔）**，实现成本低、够用；SSE 列为 P2 优化项。
2. **文件大小上限**：任务书未规定。建议默认 **20MB / 单文件**，📌 同时限制**单次任务序列数 ≤ 1000**（应对 1 分钟约束）。
3. **是否需要接口文档产出**：任务书 5.2 要求交付"API 接口文档"。建议直接用 FastAPI 自动生成的 OpenAPI（`/docs`），再导出静态文档归档。
4. **API 版本策略**：MVP 是否必须支持 v1/v2 并存？建议不做，仅保留 `/api/v1` 前缀为将来留口子。
5. 📌 **是否保留 `POST /predictions` 的异步语义**：既然 1 分钟内必然返回，建议保留"先返回 task_id 再查状态"的结构（便于以后扩展），但前端可直接等待。若追求简单，也可改为同步返回结果。

6.3 主要技术风险与应对

编号	风险	影响	概率	应对思路
R1	**加权 MAPE ≤ 20% 的目标可能达不到**	🔒 直接违反硬指标，影响答辩	中高	① 先跑通移动平均基线，量化差距；② 主指标按销量加权，长尾稀疏序列用规则兜底并单列统计；③ 📌 口径已定为"加权 MAPE 为主 + 达标序列占比为辅"（附录 C-1），不再存在口径歧义；④ 分 L1/L2 分别统计，不混算
R2	**数据泄漏**（随机切分 / 归一化用全量统计量）	指标虚高，结果不可信，属方法论错误	中	强制"按时间 8:1:1 切分"；📌 归一化改为**按序列独立**且统计量只来自训练集；代码评审列为必查项

编号	风险	影响	概率	应对思路
R3	📌 **在线预测耗时超 1 分钟**（本项目最关键的工程风险）	🔒 违反硬指标；演示失败	中	① 已实测：数据处理约 2.3 秒、10 万样本训练约 3.7 秒（附录 D），预算充裕；② **批量推理**，禁止逐序列循环；③ 设置序列数上限（建议 1000）；④ 各环节埋点计时，超时软失败；⑤ 压测作为 P1 阶段的硬门槛
R4	**SQLite 并发写入瓶颈**	多用户同时提交任务时写锁冲突	中	① 批量插入替代逐条 commit；② 开启 WAL 模式；③ 明确说明本项目为单机小规模场景，如并发要求提升需迁移 PostgreSQL（列为 V2.0）
R5	📌 **单次任务序列数过多导致超时**	直接触发 R3	中	① 序列数上限 1000（可配置），超出即提示用户筛选商品；② 三级分级自动减少实际推理量（L3 不推理）；③ 前端提前告知当前序列数
R6	📌 **2GB 显存 OOM**（MX450 被其他程序占用显存）	推理中断，任务失败	中	① 实现 CUDA→CPU 自动回退（实测模型仅 5,454 参数、峰值显存 111MB，回退后仍可在秒级完成）；② 启动时预加载模型，避免首请求承担加载开销；③ 训练脚本加 `empty_cache()`
R7	**前端上传大文件卡顿**	体验差	低	前端做大小预检 + 上传进度条 + 后端流式落盘
R8	**依赖版本冲突**（PyTorch / numpy / pandas）	环境搭不起来，开发卡壳	中	📌 已实测本机 `deploy` 环境为 torch 2.9.1+cu128 + pandas 2.3.3 + numpy 2.5.3，CUDA 可用；锁定该组合到 `requirements.txt`；提供一键环境安装脚本
R9	**数据隐私合规**（任务书 6.2）	🔒 合规红线	中	上传即脱敏/聚合；HTTPS 传输；密码哈希；文件按用户目录隔离；不将数据用于其他用途并写入用户协议

编号	风险	影响	概率	应对思路
R10	**浏览器兼容性差异**（任务书 6.4）	🔒 验收项	低	开发期固定使用标准 CSS 与主流组件库；上线前在 Chrome/Firefox/Safari/Edge 最新两版做一次回归
R11	**模型适用范围被误用**（任务书 6.3）	用户拿预测值当唯一决策依据	中	结果页固定展示适用性说明；📌 L2/L3 序列显式标注"低置信度 / 不可预测"；全局免责声明
R12	**历史记录与数据集膨胀**	磁盘占满（📌 本机 C 盘实测仅剩约 29GB）	中	定期清理过期原始文件；导出文件设 TTL；**中间文件一律放工作区内**，不写系统盘
R13	**多人协作/答辩期需求变更**	范围蔓延导致延期	中	以第三章优先级表为唯一基准，P2 项一律延后；变更需书面记录

第七章 分阶段开发排期建议与验收标准

7.1 阶段划分原则

- 每阶段都以「**可运行、可演示**」为完成标准，不允许出现"半成品阶段"。
- 算法链路优先于界面美化：**先把 M3+M4 用脚本跑通，再接 Web**，否则联调期会同时面对算法与接口两类问题。
- 每阶段结束做一次内部演示，未通过不进下一阶段。

7.2 阶段排期

⚠ 任务书未给出工期要求。以下为**按阶段顺序**的建议排期，具体日历天数需根据团队人数与可用工时确认。

阶段	名称	主要工作	关键交付物	依赖
P0	需求与技术验证	确认本文档⚠项；下载数据集；搭环境；跑通最小 LSTM demo	确认清单、环境说明、demo 脚本	——
P1	算法链路打通	M3 预处理与特征工程、M4 模型训练与评估、基线对比	可独立运行的算法脚本 + 评估报告（含 MAE/RMSE/MAPE）	P0
P2	后端服务化	数据库建表、认证、上传与校验、任务状态机、预测接口、导出	FastAPI 服务 + OpenAPI 文档 + 数据库设计文档	P1
P3	前端界面	认证页、工作台、上传页、参数页、结果页（图表+指标+表格）、历史页	React 前端 + 组件库 + UI/UX 设计文档	P2
P4	集成联调	前后端对接、异常分支联调（第三章 B1–B11）、样式统一	完整可运行的 WebApp	P3
P5	测试与优化	功能测试、边界测试、性能优化、兼容性回归	测试报告 + 性能优化版	P4
P6	文档与答辩	全套文档收敛、PPT、演示脚本准备、演示数据冻结	项目文档、演示 PPT、项目说明	P5

7.3 各阶段验收标准

P0 需求与技术验证

☐ 本文档第 1–7 章所有 ⚠ 项均已给出明确结论（是/否/取值）

☐ 目标运行环境可复现：新机器按环境说明 30 分钟内搭起可运行环境

☐ 菜鸟数据集已本地留存，抽样版本已生成

☐ 最小 LSTM demo 可跑出预测曲线（数据可粗糙，链路必须通）

☐ 已确认项目的交付物清单与任务书 5.1/5.2 完全对齐

P1 算法链路打通

☐ 预处理可处理：缺失、断档、异常尖峰、负值四类脏数据

☐ 特征工程产出：窗口样本 + 星期 + 月份 + 节假日 + 滞后 + 滚动均值

☐ 📌 序列三级分级器（L1/L2/L3）实现，并输出实测分布统计

☐ 数据切分严格按时间 8:1:1，**代码评审确认无随机切分、无跨集统计量**

☐ 📌 归一化按序列独立进行，统计量只来自训练集

☐ 训练流程含 MSE 损失、Adam + 学习率衰减、早停，且早停有日志佐证

☐ 📌 输出**加权** MAE / RMSE / MAPE + 达标序列占比，并与移动平均基线同表对比

☐ 🔒 **加权 MAPE ≤ 20%**；🔒 **加权 MAE / RMSE 相对基线降低 ≥ 15%**（若不达标，须有分析结论与改进方案，不得直接放行）

☐ 📌 L1 与 L2 的 MAPE 分开统计，未混算

☐ 模型权重文件可保存、可重新加载并复现同一结果

☐ 📌 **全量推理压测：端到端 ≤ 1 分钟**（本阶段硬门槛，不过则不进 P2）

☐ 📌 设备自动回退验证：模拟 CUDA 不可用时能自动走 CPU 且结果一致

☐ 算法层可脱离 Web 用单脚本运行完毕（架构红线自检）

P2 后端服务化

☐ 全部 P0 接口按第 6.2 节约定实现，响应结构统一

☐ 上传校验可准确拦截：缺列、日期不可解析、数据量不足、超大小

☐ 📌 仓库列作为必需字段校验，缺失即拒绝

☐ 任务状态机流转可观测（created→running→succeeded/failed），失败有明确错误码

- ☐ 📌 超时软失败验证：超 1 分钟时返回明确提示而非 502
- ☐ 📌 序列数上限拦截验证：超限时提示用户筛选商品
- ☐ 数据隔离验证：用户 A 无法通过任何接口读取用户 B 的数据集/任务/结果
- ☐ 密码以哈希存储，数据库中无明文密码
- ☐ 导出文件内容正确，列名与顺序符合定义（📌 含 granularity_level 列）
- ☐ `/health` 返回正常，OpenAPI 文档可访问且与实际接口一致

P3 前端界面

- ☐ 第 3.2 节 M1/M2/M5/M6 的 P0 功能点全部可交互
- ☐ 上传校验失败时，界面明确给出"错在哪一列/哪一行 + 怎么改"
- ☐ 结果页同时展示：折线对比图、三项指标卡、基线提升幅度、分商品表格
- ☐ 📌 覆盖率披露面板可见：L1 / L2 / L3 序列数与占比
- ☐ 📌 预测表格中每条标注 granularity_level 与置信度
- ☐ 📌 参数页不含"重新训练"选项，并说明使用预训练模型
- ☐ 加权 MAPE > 20% 时，警告提示可见且不刺眼
- ☐ 免责声明在全局可达（页脚或首启提示）
- ☐ 页面在 Chrome / Firefox / Safari / Edge 最新两版无布局错乱

P4 集成联调

- ☐ 主干路径（第 2.1 节 [1]→[9]）完整走通，无需人工介入
- ☐ 第三章 B1–B14 所有 P1 分支场景逐一验证通过
- ☐ 二次上传 / 重复提交 / 中途刷新页面等异常操作不产生脏数据
- ☐ 前后端字段名、类型、枚举值完全对齐，无隐式依赖

P5 测试与优化

☐ 功能测试用例覆盖所有 P0 功能点，通过率 100%

☐ 边界测试覆盖：空文件、单行数据、超长序列、特殊字符商品名、时区/夏令时无关性

☐ 📌 单次预测任务端到端耗时 **≤ 1 分钟**（用完整菜鸟数据集压测）

☐ 📌 并发 3 个任务提交时服务不崩溃，且各自仍在 1 分钟内完成

☐ 测试报告含失败用例、修复记录、遗留问题清单

P6 文档与答辩

☐ 任务书 5.2 要求的文档全部产出：PRD、UI/UX、数据库设计、API 接口、测试报告、部署运维手册

☐ AI 协作教程、RAG 语料库与提示词、项目说明（参数文档）按模板输出

☐ 演示 PPT 覆盖：项目概况、技术方案、实现过程、目标达成度、难点与应对

☐ 📌 演示 PPT 含性能实测数据（附录 D），作为"工程可行性"的论据

☐ 演示数据已冻结，现场演示可在 **5 分钟内**跑完"上传→预测→看结果→导出"

☐ 演示包含一个**失败分支**（如上传缺列文件）的现场展示，证明异常处理真实可用

7.4 里程碑与 Go/No-Go 判定

里程碑	判定条件	不通过时的动作
M-G1（P1 结束）	算法指标达标	不达标则不进 P2，集中攻坚算法（这是全项目最大风险点）
M-G2（P2 结束）	后端接口自测全通过	补齐接口，不启动前端大规模开发
M-G3（P4 结束）	主干路径端到端跑通	冻结新功能，只修 bug
M-G4（P6 结束）	交付物清单 100% 齐备	优先补硬性交付物

附录 A：关键问题确认清单

以下问题在任务书中**没有明确答案**。📌 标记的已由项目负责人确认，结论见附录 C；其余仍建议在 P0 阶段逐条确认。

编号	问题	为什么重要	结论 / 建议
Q1	项目总工期与团队人数?	决定阶段排期能否压缩、哪些 P1 需降为 P2	待确认，暂按阶段顺序推进
Q2	「MAPE ≤ 20%、MAE/RMSE 降低 15%」的统计口径?	直接决定算法能否判定达标，是本项目最大风险	📌 **已确认**：主口径为销量加权 MAPE，辅助报出达标序列占比；基线为移动平均。详见附录 C-1
Q3	预测粒度到底是「商品」还是「仓库×商品」?	影响数据模型与特征设计	📌 **已确认**：主粒度为仓库×商品，采用三级降级策略；仓库列为必需字段；菜鸟数据集实测为 963 商品 × 5 分仓。详见附录 C-2
Q4	预测步长上限？任务书只说"未来若干天"	影响模型结构（多步策略）与评估方式	建议 7 / 14 / 30 三档可选，默认 7
Q5	是否要求「登录后才能使用」？还是允许游客试用示例数据?	影响 MVP 工作量与首次体验	建议：游客可加载示例数据并看到完整结果，但导出与历史需登录
Q6	模型是"用户上传后即时训练"还是"预训练后用上传数据推理"?	决定等待时长是秒级还是分钟级，是体验成败关键	📌 **已确认**：纯预训练推理（等待上限 1 分钟，训练在时限内不可行）。详见附录 C-3
Q7	单次上传文件大小与行数上限?	影响存储、内存与超时设置	建议 20MB / 50 万行以内；📌 另需限制**单次任务序列数 ≤ 1000**
Q8	是否需要多语言 / 是否仅中文界面?	影响前端文案架构	建议 MVP 仅中文
Q9	部署环境？本机演示 / 内网服务器 / 云主机？是否必须公网可访问?	影响 HTTPS、并发与运维方案	⚠ 若需公网，须额外确认 HTTPS 证书与数据合规方案（任务书 6.2 要求 HTTPS）
Q10	数据库是否允许从 SQLite	影响并发能力与迁移成本	建议 MVP 用 SQLite，但

编号	问题	为什么重要	结论 / 建议
	切换到 PostgreSQL?		ORM 层不做 SQLite 专有语法，保留迁移可能
Q11	「AI 协作教程」「RAG 语料库与提示词」的验收标准是什么?	任务书 5.2 列入交付物但无描述，易在答辩时产生争议	需确认模板与篇幅要求
Q12	项目说明「参数文档」是否有既定模板?	同上，任务书写"根据模板输出"但模板未随任务书提供	需向负责人索取模板
Q13	是否需要区分"管理员"角色查看全站数据?	影响权限模型设计	建议 MVP 不设管理员角色，仅同一用户维度
Q14	异常尖峰截断的具体阈值规则?	影响预处理结果与可复现性	建议：超出 P99.5 或均值 + 3σ 的值截断至该上界，并在报告中披露
Q15	节假日特征的数据源?	需外部依赖，且要覆盖数据集时间范围	建议使用本地节假日表（含调休），避免运行时联网

附录 B：术语表

术语	含义				
SKU	最小库存单位，即具体商品规格				
MAPE	平均绝对百分比误差，越低越好，本项目硬指标 ≤ 20%				
WAPE / 加权 MAPE	按真实销量加权的 MAPE，= Σ\	y-ŷ\	/ Σ\	y\	，本项目的**主判定口径**
MAE	平均绝对误差				
RMSE	均方根误差，对大误差更敏感				

术语	含义				
滑动窗口	用连续 N 天数据预测后续值，把时序样本化的方法				
多步预测	一次预测未来多个时间点的值				
移动平均基线	用近期均值外推的朴素方法，作为"模型是否真的有用"的对照，同时兼任长尾兜底模型				
数据泄漏	训练时使用了未来信息，导致指标虚高、上线失效				
早停	验证集误差不再下降时提前结束训练，防过拟合				
L1 / L2 / L3	序列三级分级：仓库×商品建模 / 降级到商品级 / 标记不可预测				
达标序列占比	逐序列 MAPE ≤ 20% 的序列数占参与评估序列总数的比例				
预训练推理	加载离线训练好的模型直接推理，不在请求内训练				

附录 C：已确认决策记录

本附录记录项目负责人对关键问题的确认结论，作为开发依据；与正文冲突时以本附录为准。

C-1 指标统计口径（对应 Q2）

问题：任务书给出「MAPE ≤ 20%、MAE/RMSE 相对基线降低 15%」两个硬指标，但未定义统计口径。

确认结论：

项	定义				
基线方法	**移动平均**（已确认）				
主判定口径	**销量加权 MAPE**（即 WAPE）= Σ\	y_i-$\hat{y}_i$\	/ Σ\	y_i\	
辅助口径	**达标序列占比** = 逐序列 MAPE ≤ 20% 的序列数 / 参与评估序列总数				
硬指标判定	加权 MAPE ≤ 20% **且** 加权 MAE/RMSE 相对基线降低 ≥ 15%				
口径一致性要求	基线的 MAE/RMSE 必须与主模型使用**同一批预测点、同一权重**计算				

为什么选加权口径：长尾低销量序列的逐序列 MAPE 可达百分之几百，若用算术平均会把整体指标拉爆且没有业务含义；加权口径对应"整体的货量预测误差"，有明确的业务解释，且天然规避零销量除零问题。

必须披露：评估前提需注明"使用预训练模型、未针对输入数据微调"，写入 `metrics.eval_note`。

C-2 预测粒度（对应 Q3）

问题：任务书 2.2-3 说"商品销量"，1.1/2.1 又强调"分仓规划"，两处不一致。

联网查证的数据集事实（来源：菜鸟-需求预测与分仓规划赛题公开资料及参考实现）：

事实	数值
商品数	963
分仓数	5（另有全国口径）
数据时间范围	约 450 天
理论最大序列数	963 × 5 = 4,815
分布特征	长尾；大量商品"有段时间有销量、有段时间完全无数据"；分仓样本缺失 17,063 条

确认结论：

项	决策
仓库列	**必需字段**（数据集必含），缺失即拒绝上传
主粒度	**仓库 × 商品**（服务任务书的"分仓规划"卖点）
降级策略	**三级分级**：L1（有效点数 ≥ 90）/ L2（商品级聚合 ≥ 90 点，按历史占比分摊）/ L3（标记不可预测）
归一化	**按序列独立**，不做全局归一化
是否建 warehouses 表	**不建**，MVP 阶段仓库仅作分组键
覆盖率披露	L1/L2/L3 序列数与占比必须在结果页展示

为什么这样定：菜鸟数据集的核心价值就在分仓维度，若先聚合到商品级会不可逆地丢失信息；但 4,815 条序列中大量样本量不足，全量按仓建模既不可靠也无必要，故需分级而非一刀切。

C-3 训练时机（对应 Q6）

问题：用户上传数据后，是即时训练模型，还是用预训练模型推理？

关键约束：**端到端等待时间上限为 1 分钟**（已确认，且为硬约束）。

确认结论：

项	决策
在线路径	**纯预训练推理**，不训练
是否提供"重新训练"	**不提供**（1 分钟约束下物理不可行，已写入 1.4 不做清单）
字段结构一致性	**已确认一致** —— 预训练模型可直接套用，无需字段映射层
任务状态机	简化：去掉 `queued`（无长任务需排队）
模型版本	`tasks.model_version` 变为 **NOT NULL**
1 分钟预算分配	读取校验 ≤10s / 预处理 ≤10s / 特征 ≤15s / 推理 ≤15s / 指标 ≤5s / 落库返回 ≤5s

为什么不可行即时训练：单次 LSTM 训练（含早停与调参）耗时以分钟计，即便优化到极限也无法稳定在 1 分钟内；而在 1 分钟约束下，预训练推理的耗时是秒级，二者不在同一量级。

与任务书的一致性：任务书 3.3 原文为"将训练好的模型部署到服务端，通过 API 接口提供销量预测服务"——**本就指向预训练推理**，故本决策不是妥协，而是回归任务书原意。

附录 D：本机性能实测基准

以下数据在项目负责人本机实测，用于替换原文档中的估算值，同时作为"1 分钟约束可达成"的可行性证据。

D-1 硬件与软件环境

项	实测值
CPU	8 逻辑核
内存	23.8 GB（实测时可用 6.6 GB）
独显	NVIDIA GeForce MX450，**2 GB 显存**
集显	Intel Iris Xe Graphics
GPU 驱动 / CUDA	576.28 / CUDA 12.9
计算能力	7.5（Turing）
PyTorch	2.9.1+cu128（`cuda.is_available() = True`）
pandas / numpy	2.3.3 / 2.5.3
系统盘空闲	约 29 GB（⚠ 偏紧，中间文件须放工作区）

D-2 数据处理耗时（86 万行，与菜鸟分仓数据同规模）

环节	实测耗时
读取 CSV	0.43 s
groupby 分组（4,815 序列）	0.10 s
排序 + 日期解析	0.36 s
滞后特征	0.09 s

环节	实测耗时
滚动均值	1.35 s
合计	**约 2.3 秒**

D-3 模型训练耗时（LSTM：hidden=32, layers=1, window=14）

样本量	CPU	GPU(MX450)	GPU 加速比	GPU 峰值显存
4,096	0.39 s	0.32 s	1.19×	33 MB
20,000	1.58 s	0.91 s	1.73×	46 MB
50,000	3.20 s	1.13 s	2.82×	70 MB
100,000	3.67 s	0.84 s	**4.35×**	111 MB

关键结论：

1. **2 GB 显存完全够用** —— 10 万样本峰值仅占 111 MB（模型仅 5,454 参数）。原先"显存不足"的担忧不成立。
2. **数据量越大，GPU 优势越明显** —— 小数据量时存在固定启动开销，4 万样本以上才明显拉开差距。
3. **绝对耗时都很短** —— 即使纯 CPU 跑 10 万样本 3 个 epoch 也只需 3.67 秒。

D-4 对项目的影响

原假设	实测修正
在线预测可能超 1 分钟，需异步	数据处理 2.3 秒 + 推理秒级，**1 分钟预算充裕**
训练需 30–60 分钟，需 Top-N 截断省时间	实测训练仅数秒，**无需为省时间牺牲覆盖率**；Top-N 截断的理由改为"稀疏序列 LSTM 精度不如规则兜底"
2 GB 显存可能不足	**完全够用**，但需保留 CUDA→CPU 自动回退以应对显存被占用的情况

D-5 基准测试脚本

- 脚本位置：`scripts/bench_gpu.py`
- 运行环境：`C:\ProgramData\anaconda3\envs\deploy\python.exe`
- 用法：直接运行即可输出 CPU / GPU 训练与推理对比表

文档结束

本文档中未标 📌 的 ⚠ 项仍需在 P0 阶段确认。确认结果请回填至附录 C，版本号顺延至 V1.2。